final_report

October 15, 2026

1 World music consumption

1.1 Resumen

¿Estamos escuchando todos la misma música? Con la llegada del streaming, el acceso a un catálogo global sugería una convergencia hacia un consumo musical uniforme. Sin embargo, los datos apuntan en otra dirección: entre 2017 y 2021, los países se parecieron menos entre sí en lo que escuchan.

Analizamos las 200 canciones más escuchadas de 53 mercados de Spotify entre 2017 y 2021. Medimos qué tan parecidas son las listas de cada par de países (0 si son idénticas, 1 si no comparten nada) y dibujamos el mapa de sus afinidades como una red para ver la cartografía de las comunidades musicales, sin darle información geográfica al análisis. Esto es lo que encontramos:

- **El mundo musical no está globalizado, y en estos años se alejó más.** Ni siquiera al inicio los países escuchaban lo mismo: en 2017, dos países cualesquiera estaban en promedio a 0,48 de distancia, a mitad de camino entre listas idénticas y listas sin nada en común. En 2021 estaban a 0,72, un aumento cercano al 50 %, concentrado entre 2017 y 2019 y sostenido desde entonces. El resultado se repite con otras dos formas de medirlo.
- **Se redujeron las canciones global.** Las canciones presentes en el Top 200 de al menos 20 países pasaron de 138 a 74, casi la mitad, y el porcentaje de streams que concentran bajó de 56 % a 28 %, en los mismos años en que aumenta la distancia. La cima de cada lista pesa lo mismo que antes; lo que cambió es cuánto se comparte entre países.
- **El mapa de afinidades se organiza en tres comunidades que siguen, en buena medida, las regiones del mundo,** aunque el análisis no recibió información geográfica: de las 52 conexiones que forman el esqueleto del mapa, 43 unen países de la misma región (por azar serían unas 17).
  - **América Latina hispanohablante y España:** la comunidad más cohesiva. España, que es europea pero habla español, se agrupa con ellos; Brasil, de habla portuguesa, queda afuera.
  - **Asia:** los 8 mercados asiáticos del panel, en un grupo menos cohesivo.
  - **Un grupo amplio y difuso:** Europa, Norteamérica, Oceanía, Brasil y Turquía.
- **Dos de las comunidades se mantienen en el tiempo.** El grupo iberoamericano tuvo los mismos 16 países los cinco años y el asiático casi no cambió. El grupo amplio, en cambio, en 2017 estaba repartido en comunidades más pequeñas (una anglohablante y otra con Noruega y Suecia) y desde 2020 aparece como una sola.

Los datos muestran cómo se aleja y cómo se agrupa el mundo musical, pero: - ¿Qué géneros caracterizan a estas comunidades? - ¿Cuanto pesa la similitud idiomatica?, ¿la cultural?, ¿El algoritmo?

2 Índice Navegable

2.1 Capítulo 1: Introducción y Marco Metodológico

- 1.1. Objetivo del estudio
- 1.2. Marco metodológico

2.2 Capítulo 2: La Divergencia del Consumo Global

- 2.1. El fenómeno de -Convergencia
- 2.2. Hallazgos: Diversidad estructural y evolución temporal de la distancia
- 2.3. Interpretación: ¿Por qué diverge el sistema?
- 2.4. ¿Qué pasó con el mainstream? Las canciones globales y la concentración local

2.3 Capítulo 3: Estructura de las Comunidades Musicales (2021)

- 3.1. El Espacio Relacional Puro: El Árbol de Expansión Mínima (MST)
- 3.2. Identificación de Comunidades Musicales
- 3.3. Caracterización de la estructura

2.4 Capítulo 4: Estabilidad Estructural (2017–2021)

- 4.1. Descripción de la dinámica observada
- 4.2. El valor de la evidencia empírica

2.5 Capítulo 5: Conclusiones y Horizontes

- 5.1. Síntesis de hallazgos
- 5.2. Limitaciones
- 5.3. Próximos pasos (Agenda de investigación)

2.6 Anexo: Robustez de los resultados

- A.1. Sensibilidad de la partición en grupos (2021)
- A.2. Canciones globales con distintos umbrales
- A.3. Concentración de las listas

3 Estructura del Informe

- **Capítulo 1: Introducción y Marco Metodológico**
  - 1.1. Objetivos y alcance: Convergencia o segmentacion?
  - 1.2. Marco metodológico: Datos, Distancia Coseno, MST y detección de comunidades.
- **Capítulo 2: La Divergencia del Consumo Global**
  - 2.1. El fenómeno de σ-convergencia: Evolución de la dispersión (σ).

  - 2.2. Hallazgos: De la reconfiguración (2017-2019) a la estabilización (2020-2021).
  - 2.3. Interpretación: ¿Por qué diverge? (hipótesis)
  - 2.4. ¿Qué pasó con el mainstream? Las canciones globales
- **Capítulo 3: La estructura de las comunidades musicales (Foto estática 2021)**
  - 3.1. El Esqueleto del Sistema (MST): vecinos más cercanos y conexiones entre regiones.
  - 3.2. Identificación de Comunidades: los grupos de mercados.
  - 3.3. Caracterización de la estructura.
- **Capítulo 4: Análisis de la Estabilidad Estructural de las comunidades (2017–2021)**
  - 4.1. Descripción de la dinámica observada.
  - 4.2. Cautela interpretativa y limitaciones temporales.
  - 4.3. El valor de la evidencia empírica.
- **Capítulo 5: Conclusiones y Horizontes de Investigación**
  - 5.1. Síntesis de hallazgos.
  - 5.2. Limitaciones y reflexión crítica.
  - 5.3. Próximos pasos. Hacia el analisis de flujos culturales
- **Anexo:** Robustez de los resultados.

4 1. Introducción: ¿Globalización musical?

Vivimos en la era de la disponibilidad total. Por primera vez en la historia, un usuario en Tokio y otro en Buenos Aires tienen acceso al mismo catálogo de millones de canciones en la misma plataforma. Bajo esta premisa, la lógica del mercado sugeriría una convergencia inevitable: una completa globalización musical, donde las listas de éxitos serían idénticas en todo el globo.

El acceso a la información ha instalado la creencia de que vivimos en un mundo culturalmente uniforme. La narrativa predominante sugiere que, al democratizar el acceso a la música, las plataformas de *streaming* actuarían como un disolvente de las identidades locales, forzando una convergencia hacia un gusto global estandarizado. Posiblemente con un gran peso de los centros de producción hegemónicos, principalmente la industria anglosajona.

Bajo esta premisa, el *Top 200* de un país como Argentina debería ser cada vez más indistinguible del de Japón o Noruega. Sin embargo, ¿es esta la realidad que reflejan los datos? ¿Estamos realmente asistiendo al nacimiento de una globalización musical homogénea?

4.0.1 1.1. Objetivo del estudio

Este informe se propone evaluar el estado de la globalización cultural a través del análisis de consumo de Spotify en el período 2017–2021. Nuestra meta no es solo describir qué canciones son populares, sino diagnosticar si el mercado global tiende a una uniformidad en su consumo o si, por el contrario, los paises se diferencian entre sí y se agrupan en torno a afinidades regionales. Para ello, el informe responde tres preguntas:

1. ¿Existe una convergencia real? ¿Están los países escuchando música cada vez más parecida?
2. ¿Cómo se organiza el mundo musical? ¿Es la geografía el factor determinante, o existen "bloques de afinidad" que ignoran las fronteras tradicionales? ¿Y esa organización cambia durante el período?

4.0.2 1.2. Marco metodológico

Para responder a estas interrogantes, abandonamos la mera descripción de las listas de éxitos y adoptamos un enfoque sistémico. La complejidad del fenómeno requiere herramientas de **análisis de redes y análisis de convergencia**:

1. **Naturaleza del dato:** Los datos provienen del histórico de *Spotify Charts* (2017–2021). Se conservaron solo los rankings Top 200 (se descartó el Viral 50) y, para cada mercado y año, se sumaron los streams que cada canción registró en esos rankings y se seleccionaron las 200 con más streams. Cada canción se identifica por su título y su artista. Se mantuvieron los mercados con datos en los cinco años y se excluyeron "Global" y tres mercados con datos incompletos (Bulgaria, Luxemburgo y Nicaragua). El panel resultante comprende 53 mercados con 200 canciones por mercado y año (53.000 registros).

2. **Representatividad del streaming:** Al centrarse en los 200 temas con mayor volumen de reproducción, este dataset no representa la totalidad del consumo cultural de una nación, sino su **repertorio *mainstream***. Esto es metodológicamente relevante, ya que el *Top 200* es el campo de batalla donde convergen las **estrategias de marketing global**, las **preferencias masivas** y los **algoritmos de recomendación**. Aunque no abarca el consumo de nicho o fuera de plataformas, este dataset es el **estándar de facto de la industria musical actual**. Por lo tanto, cualquier divergencia o convergencia observada aquí tiene implicancias directas sobre cómo se está moldeando el gusto público y la economía de la música a escala global.

Sobre esta base, aplicamos las siguientes técnicas:

1. **Cuantificación mediante Distancia Coseno:** Definimos el perfil musical de cada país como un **vector de alta dimensionalidad** en el espacio de canciones disponibles. Cada dimensión representa una canción y su magnitud es la **cuota de mercado (*stream share*)** que esta ocupa en el consumo nacional. La **Distancia de Coseno** mide el ángulo entre estos vectores: si el ángulo es pequeño (distancia cercana a 0), los países comparten no solo el catálogo, sino las mismas prioridades e intensidades de escucha.
2. **Marco de Convergencia (σ-convergencia):** Inspirándonos en los modelos de convergencia económica de **Barro y Sala-i-Martin**, adaptamos el concepto de **σ-convergencia** al dominio cultural. Evaluamos si la **dispersión o distancia bilateral media** entre los perfiles musicales de las naciones experimenta una contracción sostenida a lo largo del tiempo.
3. **Modelado Topológico (MST):** Modelamos el mercado como un grafo ponderado de afinidades. Mediante el **Árbol de Expansión Mínima (MST)**, aislamos el **esqueleto estructural del sistema** (las conexiones estrictamente necesarias de mínima distancia), eliminando aristas redundantes para identificar el vecino más cercano de cada país y las conexiones entre regiones.
4. **Detección de comunidades:** Implementamos el algoritmo de **Greedy Modularity** sobre el grafo enriquecido con aristas del **percentil 90 de similitud**, lo que permite identificar si el sistema se particiona de manera natural en **bloques culturales o continentes musicales**.

Cargo librerias:

[1]:
```
# import os

#os.makedirs('../data/processed', exist_ok=True)
#output_path = '../data/processed/df_top200_annual.pkl'
```

```
# Lo guardás (preserva 100% los dtypes de pandas)
#df_top200_annual.to_pickle(output_path)
#print("¡Guardado exitosamente!")
```

[2]:
```
import itertools
import warnings
import matplotlib.pyplot as plt
import networkx as nx
import numpy as np
import pandas as pd
import plotly.graph_objects as go
import plotly.io as pio
import seaborn as sns
from scipy.cluster.hierarchy import dendrogram, linkage
from networkx.algorithms.community import greedy_modularity_communities
from scipy.spatial.distance import pdist, squareform
import plotly.express as px
from networkx.algorithms.community import modularity
import pandas as pd

# Configuración de renderizado de Plotly para VS Code / Jupyter
pio.renderers.default = "notebook"
warnings.filterwarnings("ignore")

# Funciones modularizadas
import src
#from src.preprocessing import load_and_process_spotify
import src.network_analysis
```

Cargo dataset preprocesado:

[3]:
```
########## IMPORTO DATA #########

#df_top200_annual = load_and_process_spotify()
df_top200_annual = pd.read_pickle('../data/processed/df_top200_annual.pkl')
print(f"¡Datos cargados con éxito! Total de filas: {len(df_top200_annual)}")
```

```
¡Datos cargados con éxito! Total de filas: 53000
```

5 2. La Divergencia del Consumo Global

Para evaluar el grado de integración musical, hemos definido la distancia entre dos países mediante la **Distancia de Coseno** ($1 -$ Similitud de Coseno), aplicada sobre la cuota de mercado (*stream share*) de cada canción.

5.0.1 2.1. El fenómeno de σ-Convergencia

Para diagnosticar si el sistema tiende a la homogeneidad, analizamos la evolución temporal de la **Distancia Coseno Media** ($\bar{d}_t$) de todas las duplas de países, un indicador adaptado de la σ-convergencia. Si el *streaming* fuera una fuerza democratizadora, observaríamos una caída sostenida en estas distancias.

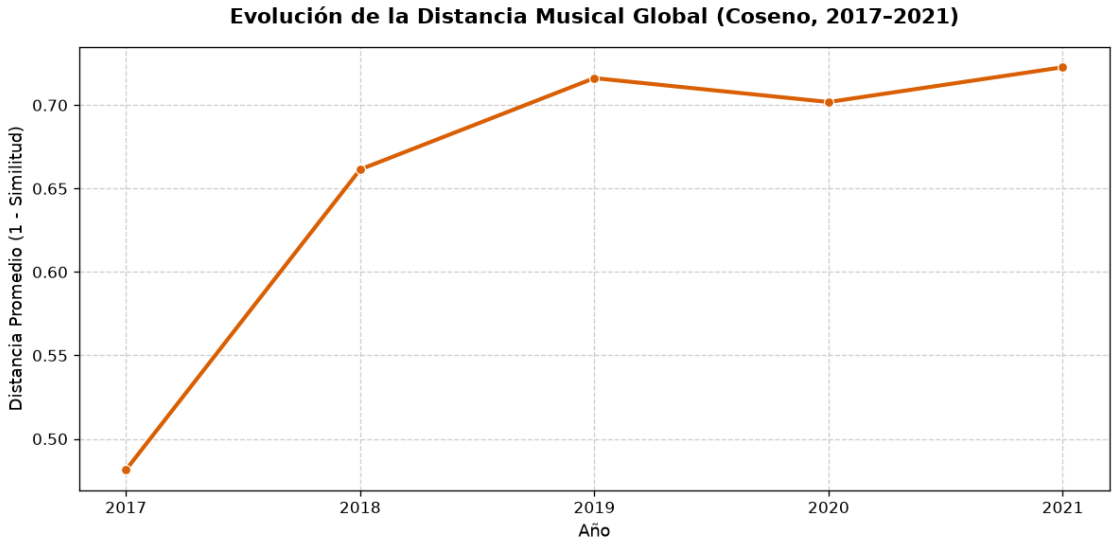
[4]:
```
from src.network_analysis import calculate_cosine_similarity_matrix,␣
 ↪build_convergence_table, calculate_sigma_convergence

# 1. Construir tabla de distancias usando Coseno
df_dist_coseno = build_convergence_table(df_top200_annual,␣
 ↪calculate_cosine_similarity_matrix)

# 2. Calcular estadísticas de convergencia
sigma_df = calculate_sigma_convergence(df_dist_coseno)

# 3. Graficar
plt.figure(figsize=(10, 5), dpi=120)
sns.lineplot(
    data=sigma_df,
    x="year",
    y="mean_distance",
    marker="o",
    color="#d95f02",
    linewidth=2.5
)

plt.title("Evolución de la Distancia Musical Global (Coseno, 2017-2021)",␣
 ↪fontsize=13, fontweight="bold", pad=15)
plt.xlabel("Año", fontsize=11)
plt.ylabel("Distancia Promedio (1 - Similitud)", fontsize=11)
plt.xticks([2017, 2018, 2019, 2020, 2021])
plt.grid(True, linestyle="--", alpha=0.6)
plt.tight_layout()
plt.show()
```



[5]:
```
print(sigma_df)
```

```
   year  mean_distance  std_distance
0  2017       0.481385      0.235217
1  2018       0.661434      0.255655
2  2019       0.716191      0.252862
3  2020       0.701859      0.254651
4  2021       0.722703      0.244201
```

La distancia coseno media pasa de 0,48 en 2017 a 0,72 en 2021, un aumento de aproximadamente 50 %. La serie es: 0,48 (2017), 0,66 (2018), 0,72 (2019), 0,70 (2020) y 0,72 (2021). En el marco de la σ-convergencia, esto no respalda la homogeneización: la distancia no se contrajo, aumentó.

5.0.2 2.2. Hallazgos: Diversidad estructural y evolución temporal de la distancia

Los datos muestran que el consumo musical global analizado no constituye un **sistema homogéneo**. La **distancia media** está lejos de acercarse a 0 y la **dispersión** entre pares de países se mantiene alta de manera constante (con una desviación estándar que oscila entre 0,24 y 0,26 en todos los años), lo que confirma que existen **diferencias estructurales** profundas y persistentes entre los distintos mercados.

Al observar la trayectoria de la distancia media a lo largo de la serie temporal, los datos dividen el período en dos etapas diferenciadas por su tendencia:

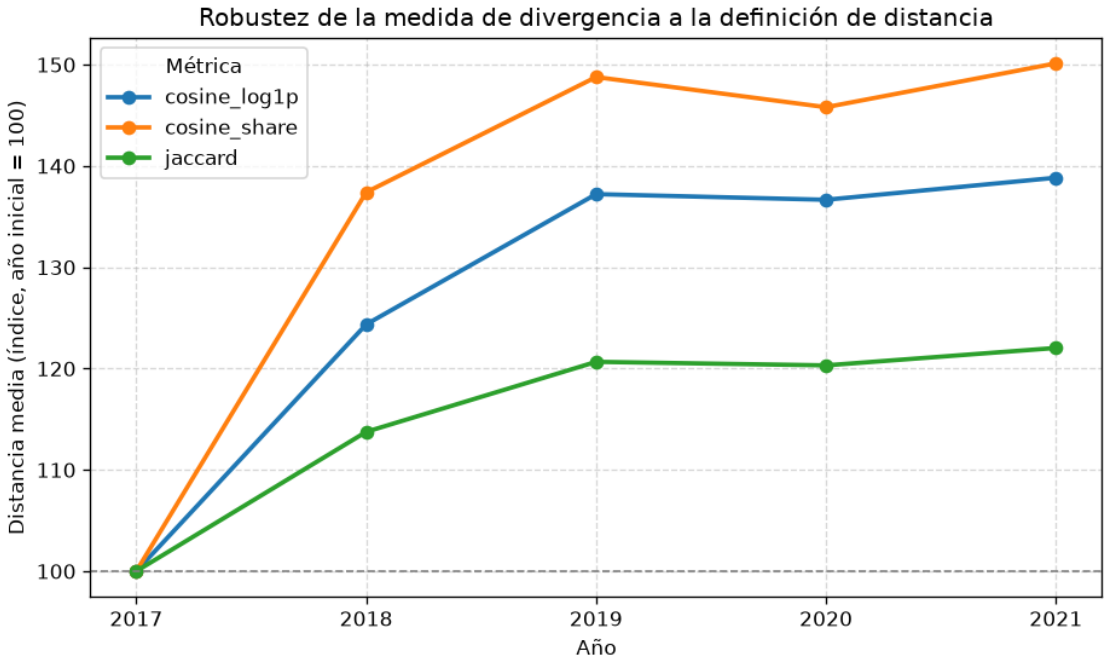
1. **Fase de divergencia (2017–2019):** Se registra un **incremento sostenido de la distancia media** entre los mercados musicales, un proceso en el cual ocurre el **97% del aumento total acumulado** en todo el período analizado. Matemáticamente, esto indica que los charts nacionales se volvieron más distantes y diferenciados entre sí.
2. **Fase de estabilización (2020–2021):** El indicador interrumpe su crecimiento y alcanza una **meseta**, estabilizando los niveles de distancia promedio en un rango de entre **0,70 y**

0,72. Esto refleja que el grado de diferenciación entre los mercados alcanzó un **punto de equilibrio** estacional o estructural dentro de la ventana temporal estudiada.

Para comprobar que el resultado no depende de cómo se mide la distancia, repetimos el cálculo con otras dos definiciones: coseno con `log1p`, que atenúa el peso de las canciones más escuchadas, y Jaccard, que solo considera qué canciones aparecen en el Top 200 de cada país, sin volúmenes.

[6]:
```
from src.network_analysis import compute_metric_robustness,␣
↪plot_metric_robustness

rob = compute_metric_robustness(df_top200_annual)
plot_metric_robustness(rob)
plt.show()
```



Las tres definiciones aumentan con el mismo patrón: de 0,48 a 0,72 con coseno sobre *stream share*, de 0,55 a 0,77 con coseno `log1p` y de 0,70 a 0,86 con Jaccard.

Los valores iniciales confirman la ausencia de un consumo homogéneo a nivel global, y todas las mediciones replican de forma consistente las **dos fases estructurales** identificadas (el proceso de divergencia continua seguido por la estabilización o meseta hacia el tramo final del período). Esto demuestra que las conclusiones sobre la fragmentación y el equilibrio de los mercados son independientes de la parametrización matemática elegida

5.0.3 2.3. Interpretación: ¿Por qué diverge el sistema?

Si las plataformas de streaming ofrecen un acceso global a catálogos masivos en todo el planeta, la tendencia esperable bajo un supuesto de uniformidad sería la convergencia. Sin embargo, los datos

muestran el proceso opuesto: **divergencia**.

Esto indica que los mercados no operan como un sistema integrado que se homogeneiza con el tiempo. Por el contrario, la ampliación de la distancia media sugiere que las dinámicas de consumo —mediadas por catálogos locales y sistemas de recomendación que operan a nivel regional— amplifican las diferencias estructurales entre los charts nacionales en lugar de reducirlas.

5.0.4 2.4. ¿Qué pasó con el mainstream? Las canciones globales y la concentración local

Debido al gran aumento inicial de la distancia, cabe preguntarse qué ocurrió con el *mainstream* en estos años. Para abordar esta cuestión, se examinan dos dinámicas complementarios:
- **Canciones globales** siendo las que logran presencia simultánea en al menos 20 mercados en el Top200 en un año dado (medida por el `Global songs count` y `Global songs share`) - **Concentración local del consumo**, medida a través de la cuota promedio de reproducciones capturada por las 10 canciones más escuchadas en cada país (medida por el `top_k_share_mean`).

[7]:
```
from src.network_analysis import compute_concentration_diagnostics
#importlib.reload(src.network_analysis)

conc = compute_concentration_diagnostics(df_top200_annual, top_k=10,␣
 ↪min_markets=20)
print(conc[["year", "global_songs_count", "global_songs_share",␣
 ↪"top_k_share_mean"]].round(3))
```

	year	global_songs_count	global_songs_share	top_k_share_mean
0	2017	138	0.561	0.152
1	2018	108	0.393	0.137
2	2019	91	0.310	0.145
3	2020	85	0.304	0.141
4	2021	74	0.279	0.147

Los datos revelan una contracción del repertorio compartido: entre 2017 y 2021, la cantidad de canciones globales se redujo casi a la mitad (de 138 a 74), y su peso en las reproducciones cayó del **56,1% al 27,9%**.

En contraste, la concentración local del consumo (`top_10_share_mean`) se mantuvo notablemente estable alrededor del 14%–15%. Esto indica que la fragmentación observada entre los mercados no responde a un encierro en listas locales más concentradas, sino a una menor superposición de los repertorios de éxito a escala global.

6 3. Estructura del las comunidades musicales: Análisis de Redes y Comunidades

Habiendo descrito que el sistema musical global diverge, el siguiente paso metodológico consiste en ver cómo se organiza esta diversidad. Si el mundo no es una unidad homogénea, ¿cuáles son sus fracturas, sus bloques de afinidad y sus conexiones? Este capítulo busca qué países se parecen entre sí, cuáles quedan en el medio y si esas afinidades siguen las fronteras geográficas o las cruzan.

Para responder a esto, adoptamos una estrategia en tres etapas secuenciales: 1. **El espacio relacional puro (El MST):** Extraemos el Árbol de Expansión Mínima para simplificar la red global y aislar las conexiones bilaterales más fuertes (la "columna vertebral" del consumo), basándonos exclusivamente en la distancia de coseno y prescindiendo de la geografía. 2. **La estructura de comunidades (La Red):** Aplicamos algoritmos de detección de comunidades sobre el grafo para identificar agrupamientos latentes (clusters de países con patrones de escucha altamente homogéneos) a partir de la topología intrínseca. Proyectamos las comunidades identificadas sobre el mapa geográfico para evaluar en qué medida las fronteras culturales coinciden con los límites continentales o responden a dinámicas transnacionales.

> **Nota metodológica sobre el año de referencia (2021):** Para este análisis estructural seleccionamos el año **2021** por dos criterios: 1. **Cierre de la serie temporal:** Representa la observación más reciente disponible en el dataset. 2. **Régimen estable:** Entre 2019 y 2021 la distancia media se mantiene entre 0.70 y 0.72, y la partición en grupos de 2020 es idéntica a la de 2021. Trabajar con un único año evita además mezclar repertorios de canciones de diferentes años en una agregación artificial.

6.0.1 3.1. El Espacio Relacional Puro: El Árbol de Expansión Mínima (MST)

Para limpiar el ruido de las conexiones marginales, extrajimos el **Árbol de Expansión Mínima (MST)**. Esta técnica conserva exclusivamente las 52 aristas fundamentales (N - 1) que mantienen al grafo conectado minimizando la distancia total.

El MST nos permite observar la "columna vertebral" del consumo musical. En la figura, el tamaño de cada nodo crece con el volumen de streams del Top 200 del mercado, lo que permite ver no solo qué países se parecen, sino también cuáles pesan más en el panel.

[8]:
```
from src.network_analysis import plot_musical_mst_network
fig =plot_musical_mst_network(
    df_top200=df_top200_annual,
    calculate_distance_func=lambda df, y: 1.0 -␣
 ↪calculate_cosine_similarity_matrix(df, y),
    year=2021
)
fig.show()
```

Vecinos más cercanos (hojas del árbol).
- **España → Perú** (dist. 0,29): confirma lazos iberoamericanos por encima de la geografía europea.
- **EE. UU. → Canadá** (dist. 0,15): pareja anglo-norteamericana más ajustada del panel.
- **Brasil → Portugal** (dist. 0,68): conexión lusófona, pero a una distancia alta (cercana al promedio global 0,72), lo que indica que Brasil *no* es un gemelo de Portugal en consumo mainstream.
- **Turquía → Letonia** (dist. 0,52): vecindad inesperada que sugiere que Turquía comparte más repertorio con el norte de Europa que con su entorno geográfico próximo.

Alineación geográfica.
De las **52 aristas del MST, 43 unen países de la misma región macroseleccionada** (América Latina, Europa, Norteamérica/Oceanía, Asia). Bajo aleatoriedad se esperarían ~17. El test de permutación (20.000 iteraciones) da una media de 17,1 y un máximo observado de 28; el valor real (43) está **muy por encima del azar ($p < 0.001$)**, confirmando que la geografía física sigue siendo el principal organizador del consumo a gran escala.

[9]:
```
from src.network_analysis import (
    mst_edges, mst_structure, mst_region_alignment, CONTINENTES_NOMBRES
)

edges_2021 = mst_edges(df_top200_annual, 2021)

_, hojas = mst_structure(edges_2021)
print({p: hojas[p] for p in ["Spain", "Brazil", "United States", "Turkey"]})

regiones = {**CONTINENTES_NOMBRES,
            "United States": "Norteamérica", "Canada": "Norteamérica",
            "Australia": "Oceanía", "New Zealand": "Oceanía"}
res = mst_region_alignment(edges_2021, labels=regiones)
print(res["observadas"], "de", res["total"],
      "| azar: media", round(res["perm_media"], 1), ", máx", res["perm_max"])
print(res["cruces"][["region_a", "region_b", "distance"]].round(2))
```

```
{'Spain': 'Peru', 'Brazil': 'Portugal', 'United States': 'Canada', 'Turkey':
'Latvia'}
43 de 52 | azar: media 17.0 , máx 31
     region_a   region_b  distance
0   Australia     Canada      0.15
1   Australia    Ireland      0.19
2      Canada     Latvia      0.27
3        Peru      Spain      0.29
4      Canada  Singapore      0.39
5      Canada   Portugal      0.41
6      Canada    Iceland      0.46
7      Brazil   Portugal      0.68
8  Costa Rica   Portugal      0.74
```

Las 9 conexiones que cruzan regiones, con su distancia coseno, son: Australia–Irlanda (0,19), Canadá–Letonia (0,27), España–Perú (0,29), Canadá–Singapur (0,39), Canadá–Portugal (0,41), Canadá–Islandia (0,46), Brasil–Portugal (0,68), Costa Rica–Portugal (0,74) y Australia–Canadá (0,15). Como la distancia media entre un par cualquiera de países es 0,72, Brasil–Portugal y Costa Rica–Portugal unen países a distancias comparables a la de un par cualquiera. Portugal tiene tres conexiones (Brasil, Canadá y Costa Rica) y ninguna con España.

6.0.2 3.2. Identificación de Comunidades Musicales

> Nota metodológica algoritmo de red: Se utilizó el algoritmo **Greedy Modularity** sobre un grafo formado por las conexiones del MST y todas las de similitud igual o superior al **percentil 90**, ponderadas por la similitud.

Al aplicar el algoritmo de modularidad (*Greedy Modularity*) sobre el grafo de percentil 90 en 2021, el sistema se particiona en **tres grupos**:

[10]:
```
from src.network_analysis import detect_musical_clusters,␣
↪plot_clusters_choropleth
```

```
# 1. Detectar clústeres para 2021
df_clusters_2021, G_2021 = detect_musical_clusters(
    df_top200=df_top200_annual,
    year=2021,
    percentile_cutoff=90,
    include_mst=True
)

# 2. Mostrar exclusivamente el mapa coroplético
fig_mapa_2021 = plot_clusters_choropleth(df_clusters_2021)
fig_mapa_2021.show(config={'scrollZoom': False, 'displayModeBar': False})
```

[11]:
```
from src.network_analysis import calculate_intracluster_cohesion

# Calcular la cohesión interna exacta de cada bloque en 2021
df_cohesion_2021 = calculate_intracluster_cohesion(df_clusters_2021,␣
 ↪df_top200_annual, year=2021)
print(df_cohesion_2021)
```

```
  cluster_id  n_paises  similitud_media  distancia_media  std_distancia
0  Cluster_1        29           0.4202           0.5798         0.2022
1  Cluster_2        16           0.7781           0.2219         0.1146
2  Cluster_3         8           0.3213           0.6787         0.1965
```

Cluster 2: bloque iberoamericano (alta cohesión)

- **Composición:** 15 de los 16 mercados de América Latina del panel (todos excepto Brasil) y España.
- **Cohesión:** es el único cluster con identidad claramente definida. Tiene la mayor similitud media (0.78), la menor distancia media (0.22) y la menor dispersión (std 0.11). La distancia media entre un par cualquiera de países es 0.72.
- **Lectura:** el grupo coincide con el idioma: los 16 países tienen el español como idioma oficial y ningún otro mercado del panel lo tiene. España, que es europea, queda dentro del bloque, mientras que Brasil, que es sudamericano pero de habla portuguesa, queda fuera. Esto sugiere que el idioma pesa más que la cercanía geográfica en la formación de este grupo.

Cluster 1: Angloesfera + europa continental (cohesión baja-moderada)

- **Composición:** 29 países. Combina la anglosfera (Estados Unidos, Reino Unido, Canadá, Australia, Nueva Zelanda, Irlanda) con Europa continental (Alemania, Francia, Países Bajos, países nórdicos, etc.), Brasil y Turquía.
- **Cohesión:** similitud media de 0.42, distancia media de 0.58 y std de 0.20. La cohesión es baja-moderada y hay mucha variabilidad interna.
- **Lectura:** es el grupo menos estable al cambiar el método: se une al grupo 3 con el percentil 80 y se divide en dos subgrupos con el 95.

Cluster 3: bloque asiático (cohesión más baja)

- **Composición:** 8 países: Japón, Filipinas, Indonesia, Malasia, Singapur, Taiwán, Hong Kong y Tailandia, es decir, los 8 mercados asiáticos del panel.
- **Cohesión:** es el menos cohesivo de los tres (similitud 0.32, distancia 0.68, std 0.20). Su distancia interna es apenas menor que la de un par cualquiera (0.72).
- **Lectura:** el grupo coincide exactamente con la región geográfica: son los 8 mercados de Asia, aunque la red se construye sin información geográfica. Una posible explicación, es que las diferencias culturales entre Asia y Occidente se reflejen en el consumo musical. Dentro del grupo la cohesión es baja (0.68 contra 0.72 del promedio), lo que es compatible con la diversidad cultural entre los países asiáticos.

Para evaluar qué tan sólida es esta partición, la repetimos con otros percentiles (80, 85 y 95) y con un clustering jerárquico de enlace completo (ver anexo). El grupo asiático se mantiene idéntico con los percentiles 85, 90 y 95 y con el jerárquico, y el de América Latina y España es idéntico con los percentiles 80, 85 y 90; con el 95 se mantienen juntos 14 de sus 16 países. El grupo amplio (Europa, Norteamérica, Oceanía, Brasil y Turquía) es el menos estable: con el percentil 85 se separan 2 de sus 29 países, con el jerárquico cambia 1 de grupo, con el percentil 80 se une al grupo asiático y con el 95 se divide en dos subgrupos de 17 y 12 países. El número de grupos varía de 2 a 5 según el percentil, por lo que no lo interpretamos por sí solo. El detalle está en el anexo.

6.0.3 3.3. Caracterización de la estructura

Lo que muestran los datos. Los tres grupos coinciden en buena medida con las regiones del mundo, aunque la red se construyó sin ninguna información geográfica. Hay tres diferencias: Europa, Norteamérica y Oceanía forman un solo grupo, España está con América Latina y Brasil está con Europa. Los grupos tampoco son igual de sólidos. El de América Latina y España es claramente cohesivo (sus países están a 0,22 entre sí, frente a 0,72 de un par cualquiera de países), mientras que el amplio (0,58) y el asiático (0,68) están mucho más cerca de ese promedio. Visto en el mapa, el resultado recuerda a placas tectónicas de distinta solidez.

El grupo iberoamericano y el idioma. Los 16 países de este grupo tienen el español como idioma oficial y ningún otro mercado del panel lo tiene; este dato es contexto externo, no una medición de este informe. Lo que sí muestran los datos es el patrón de pertenencia: España, que está en Europa, se agrupa con América Latina, y Brasil, que está en América del Sur pero habla portugués, queda fuera (su mercado más cercano es Portugal, a una distancia de 0,68, próxima al promedio). Esto sugiere que, en este grupo, el idioma pesa más que la cercanía geográfica.

El grupo asiático y el contexto cultural. El grupo reúne a los 8 mercados asiáticos del panel y a ningún otro. Como contexto, ajeno a los datos de este informe, las culturas de Asia y de Occidente son distintas, y es posible que esa diferencia se refleje en lo que se escucha. Es una hipótesis: los datos muestran que los mercados asiáticos se agrupan, pero no por qué. La baja cohesión del grupo (0,68) es compatible con la diversidad entre los propios países asiáticos, que no comparten un idioma.

El grupo amplio. Reúne a la anglosfera, Europa continental, Brasil y Turquía. Es el más heterogéneo (desviación estándar de 0,20) y cómo se verá en la proxima seccion su estructura es la menos estable temporalmente, por lo que su estructura interna es la menos firme de las tres.

7 4. Análisis de la Estabilidad Estructural (2017-2021)

Al examinar la composición de los grupos a lo largo del período, se observa que la organización de los mercados musicales no ha sido inmutable, aunque el cambio no es parejo: dos de los tres grupos mantienen casi sin cambios su composición (Asia suma a Tailandia en 2018) y la variación está en el resto. La composición cambia en cada paso entre 2017 y 2020, y la de 2020 es idéntica a la de 2021.

[12]:
```
import plotly.express as px

def generar_y_graficar_todos_los_anios(df_top200_annual, percentile_cutoff=90):
    """
    Detecta clústeres y genera el mapa coroplético para cada año,
    centrado en África, sin zoom, sin barra de herramientas, con la latitud␣
 ↪ajustada en 25
    y una paleta de colores fija por clúster.
    """
    # Obtener la lista ordenada de todos los años disponibles
    anios = sorted(df_top200_annual['year'].unique())

    print(f"Se encontraron {len(anios)} años para procesar: {anios}\n")

    # Mapeo de colores fijo:
    # Cluster 1: azul, Cluster 2: verde, Cluster 3: violeta, Cluster 4: rojo,␣
 ↪Cluster 5: naranja
    colores_clusters = {
        "Cluster_1": "#1f77b4",  # Azul
        "Cluster_2": "#2ca02c",  # Verde
        "Cluster_3": "#9467bd",  # Violeta
        "Cluster_4": "#d62728",  # Rojo
        "Cluster_5": "#ff7f0e"   # Naranja
    }

    for anio in anios:
        print(f"--- Procesando año {anio} ---")

        # 1. Detectar clústeres para el año actual
        df_clusters_anio, _ = detect_musical_clusters(
            df_top200=df_top200_annual,
            year=anio,
            percentile_cutoff=percentile_cutoff,
            include_mst=True
        )

        # Verificar que el DataFrame no esté vacío
        if df_clusters_anio.empty:
            print(f"No hay datos suficientes para el año {anio}.\n")
```

```
            continue

        # 2. Preparar los datos para Plotly
        n_clusters = df_clusters_anio["cluster_id"].nunique()
        percentil = df_clusters_anio["percentile_cutoff"].iloc[0]

        df_plot = df_clusters_anio.copy()
        df_plot = df_plot.rename(columns={'region': 'pais', 'cluster_size':␣
↪'integrantes_cluster'})
        df_plot['cluster_id'] = df_plot['cluster_id'].astype(str)

        # Asegurar que tengan el prefijo exacto para coincidir con el␣
↪diccionario de colores (ej. "Cluster_1")
        if not df_plot['cluster_id'].iloc[0].startswith("Cluster_"):
            df_plot['cluster_id'] = "Cluster_" + df_plot['cluster_id']

        # 3. Crear la figura con los colores fijos asignados
        fig = px.choropleth(
            df_plot,
            locations="pais",
            locationmode="country names",
            color="cluster_id",
            hover_name="pais",
            hover_data={"integrantes_cluster": True, "cluster_id": True, "year":
↪ True},
            title=f"Clústeres de Consumo Musical - Año {anio} (Percentil␣
↪{percentil}%) - Total: {n_clusters} Clústeres",
            color_discrete_map=colores_clusters # <--- Asigna los colores fijos␣
↪por ID de clúster
        )

        # Configuración con África en el centro, el desplazamiento vertical␣
↪ajustado a 25 y sin cortes en el norte
        fig.update_layout(
            geo=dict(
                showframe=False,
                showcoastlines=True,
                projection_type="natural earth",
                center=dict(lat=25, lon=20), #
                projection_rotation=dict(lon=20)
            ),
            dragmode=False,
            legend_title_text="ID de Clúster",
            margin={"r":0, "t":50, "l":0, "b":0}
        )
```

```
        # Mostrar el gráfico sin zoom por scroll ni barra de herramientas
        fig.show(config={
            'scrollZoom': False,
            'displayModeBar': False,
            'doubleClick': False
        })

# Ejecutar el proceso completo para todos los años:
generar_y_graficar_todos_los_anios(df_top200_annual, percentile_cutoff=90)
```

```
Se encontraron 5 años para procesar: [np.int32(2017), np.int32(2018),
np.int32(2019), np.int32(2020), np.int32(2021)]

--- Procesando año 2017 ---

--- Procesando año 2018 ---

--- Procesando año 2019 ---

--- Procesando año 2020 ---

--- Procesando año 2021 ---
```

7.0.1 4.1. Descripción de la dinámica observada

América Latina y España se mantienen siempre. Los mismos 16 países forman este grupo en los cinco años. Es una estabilidad que coincide con que sea el grupo más cohesivo de 2021 (0,22) y con que sus miembros compartan el español como idioma oficial (dato de contexto, ajeno a la medición).

Asia también se mantiene. Siete de sus países (Japón, Filipinas, Indonesia, Malasia, Singapur, Taiwán y Hong Kong) forman un grupo los cinco años. Tailandia, que en 2017 estaba en el grupo europeo, se suma en 2018 y desde entonces el grupo es idéntico.

El grupo amplio estuvo más subdividido. Los 29 países de Europa, Norteamérica, Oceanía, Brasil y Turquía:

- **2017:** se repartían en tres grupos: uno amplio de 21 países, uno anglohablante (Estados Unidos, Reino Unido, Canadá, Australia, Nueva Zelanda e Irlanda; como contexto, el inglés es el idioma predominante en estos seis) y uno formado solo por Noruega y Suecia.
- **2018:** la anglosfera y Noruega y Suecia ya están dentro del grupo amplio, y aparece un grupo aparte con Alemania, Austria, Italia y Suiza.
- **2019:** ese grupo aparte suma a Brasil y Portugal.
- **2020–2021:** los 29 países forman un único grupo.

Estos reagrupamientos son compatibles con que el grupo amplio tenga subestructura, en línea con su cohesión baja y con su inestabilidad al cambiar el método (sección 3.2). Qué agrupaciones internas son las relevantes, por ejemplo una anglohablante o una nórdica, excede este análisis. Quedan como hipótesis para profundizar.

7.0.2 4.2. El valor de la evidencia empírica

Más allá de los factores que motivaron estos reacomodamientos —cuyo análisis causal requeriría variables sociodemográficas y de oferta discográfica detalladas por mercado—, los datos muestran que el consumo musical contemporáneo no responde a un consumo musical global homogéneo.

La estructura que se observa tiene un **núcleo estable** (el grupo de América Latina y España y el asiático, que mantienen casi sin cambios su composición) y una **zona más fluida** (los 29 países de Europa, Norteamérica, Oceanía, Brasil y Turquía, cuya subdivisión cambia de un año a otro).

8 5. Conclusiones y Horizontes de Investigación

El presente informe ha analizado la estructura global del consumo musical a través del lente de la distancia de coseno y la teoría de redes, poniendo a prueba la narrativa de una homogeneización cultural impulsada por las plataformas de streaming.

8.0.1 5.1. Síntesis de hallazgos

El análisis del consumo mainstream de Spotify en 53 mercados (2017–2021) arroja cinco resultados empíricos:

1. **Divergencia sostenida y estabilización.** La distancia coseno media entre países aumentó ~50 % (0,48 → 0,72) entre 2017 y 2021. El 97 % del incremento ocurrió en 2017–2019; 2020–2021 muestra una meseta (0,70–0,72). El patrón se replica con métricas *cosine log1p* y *Jaccard*, confirmando que no es un artefacto de la definición de distancia.

2. **Contracción del repertorio compartido (canciones globales).** Las canciones presentes en 20 mercados cayeron de 138 (2017) a 74 (2021); su participación en los streams pasó de 56 % a 28 %. La concentración local (top 10 por país) permaneció estable en 14 %–15 %. La fragmentación no proviene de listas más cerradas, sino de **menor superposición internacional** de los éxitos.

3. **Estructura modular predominantemente regional.** El Árbol de Expansión Mínima (MST) —el esqueleto de 52 aristas que minimiza la distancia global— coloca **43 de 52 conexiones (83 %) dentro de la misma macrorregión** (América Latina, Europa, Norteamérica/Oceanía, Asia). Bajo aleatoriedad se esperan ~17 (test de permutación $p < 0{,}001$). La geografía física es el principal organizador de la similitud musical a gran escala.

4. **Tres comunidades con distinta cohesión y estabilidad (2021).**

   - **Iberoamérica + España (16 países):** única comunidad de alta cohesión (distancia intra-grupo 0,22 vs 0,72 global). Composición idéntica los 5 años, membresia temporal constante.

   - **Asia (8 países):** comunidad geográficamente pura, pero cohesión baja (distancia intra-grupo 0,68). Composición estable desde 2018, membresia remporal relativamente constante
   - **Anglo-Europa + Brasil + Turquía (29 países):** comunidad extensa, heterogénea (std 0,20) y la única inestable al variar parámetros o método, es decir que la membresia de sus paises no es constante.

5. **Puentes culturales específicos en el MST.** Las 9 aristas inter-regionales del MST revelan tres patrones no geográficos:

    - **Portugal** es nodo bisagra lusófono (une a Brasil y Costa Rica con Europa), pero **no conecta con España** (España va a Perú).

    - **Núcleo anglófono** de distancias ultracortas: Australia–Canadá (0,15), Australia–Irlanda (0,19), EE. UU.–Canadá (0,15).

8.0.2 5.2. Limitaciones

Estos hallazgos están acotados por el diseño del estudio:

- **Ventana temporal (5 años).** No permite distinguir si la meseta 2020–2021 es un equilibrio estructural o una pausa transitoria.
- **Panel de 53 mercados.** Resultados válidos solo para los mercados de Spotify con serie completa; no generalizables al conjunto de naciones.
- **Definición de comunidad.** La partición depende del grafo (MST + percentil 90) y del algoritmo (Greedy Modularity). Con otros percentiles el número de clusters 2021 varía de 2 a 5; el análisis prioriza composición sobre conteo.
- **Solo consumo (lado de la demanda).** No se observan variables de oferta (catálogo local, inversión A&R, campañas), ni metadatos de artista (nacionalidad, género, idioma de la letra).
- **Granularidad del dato.** Top 200 anual agregado; remixes/versiones con distinta ortografía cuentan como canciones distintas; no hay datos demográficos de oyentes.

8.0.3 5.3. Próximos pasos (Agenda de investigación)

Los datos abren cuatro líneas de trabajo concretas para pasar de la *foto estática* a la *explicación causal*:

1. **Caracterización por género y metadatos de artista.**
   Enriquecer cada traza (país-año-canción) con género principal, idioma de la letra y nacionalidad del artista. Permitirá medir:

    - ¿Qué géneros impulsan la cohesión iberoamericana vs. la fragmentación asiática?

    - Cuota de artistas locales vs. internacionales en el top 10 de cada cluster.

    - "Balanza comercial cultural": flujos netos de nacionalidad de artista entre clusters.

2. **Integración de variables exógenas (idioma, PIB, índice cultural).**
   Testear explícitamente el peso del idioma compartido (dummy lingüístico) vs. distancia geográfica vs. similitud económica en un modelo de gravedad o regresión diádica sobre la distancia coseno.

3. **Análisis direccional de flujos (lead-lag).**
   Usar series semanales/mensuales para detectar **direccionalidad de difusión**: ¿quién "importa" éxitos de quién? (Granger-causality en redes, o *diffusion maps* temporales). Esto ataca la pregunta de si el algoritmo amplifica centros hegemónicos o permite flujos multidireccionales.

4. **Zoom en la comunidad Anglo-Europa.**
   Aplicar detección de comunidades *multi-resolución* (Leiden/Louvain con *resolution parameter*, o HDBSCAN sobre embeddings de canciones) para resolver si la inestabilidad observada refleja sub-comunidades reales (anglo, nórdica, DACH, mediterránea) o ruido metodológico.

5. **Extensión temporal y de mercados.**
   Incorporar 2022–2024 y mercados emergentes (India, África, Oriente Medio) para testar si la meseta se sostiene y si aparecen nuevos polos de cohesión.

9 Anexo: Robustez de los resultados

9.0.1 A.1. Sensibilidad de la partición en grupos (2021)

Se repitió la partición con otros percentiles y con un clustering jerárquico sobre la distancia coseno, cortado en 3 grupos. ARI es el índice de Rand ajustado (1 indica particiones idénticas y 0, un acuerdo equivalente al azar). Las columnas J son, para cada grupo de la partición de referencia, el mayor índice de Jaccard con algún grupo de la alternativa.

[13]:
```
from src.network_analysis import cluster_sensitivity

sens = cluster_sensitivity(df_top200_annual, year=2021)
print(sens.to_string())
```

```
                                    metodo  n_aristas  n_grupos
tamanos  ARI_vs_ref  Q_grafo_ref  J_Cluster_1  J_Cluster_2  J_Cluster_3
0                Greedy modularity, percentil 80      286.0         2
37/16       0.672        0.449        0.784        1.000        0.216
1                Greedy modularity, percentil 85      221.0         4
27/16/8/2       0.917        0.463        0.931        1.000        1.000
2  Greedy modularity, percentil 90 (referencia)      157.0         3
29/16/8       1.000        0.464        1.000        1.000        1.000
3                Greedy modularity, percentil 95       99.0         5
17/14/12/8/2       0.624        0.441        0.586        0.875        1.000
4                    Jerárquico (average), k=3        NaN         3
51/1/1       0.016       -0.000        0.538        0.314        0.135
5                   Jerárquico (complete), k=3        NaN         3
28/17/8       0.933        0.460        0.966        0.941        1.000
```

Método	Grupos	Tamaños	ARI	J grupo 1	J grupo 2	J grupo 3
Greedy modularity, percentil 80	2	37/16	0,67	0,78	1,00	0,22
Greedy modularity, percentil 85	4	27/16/8/2	0,92	0,93	1,00	1,00

Método	Grupos	Tamaños	ARI	J grupo 1	J grupo 2	J grupo 3
Greedy modularity, percentil 90 (referencia)	3	29/16/8	1,00	1,00	1,00	1,00
Greedy modularity, percentil 95	5	17/14/12/8/2	0,62	0,59	0,88	1,00
Jerárquico (enlace promedio), k = 3	3	51/1/1	0,02	0,54	0,31	0,14
Jerárquico (enlace completo), k = 3	3	28/17/8	0,93	0,97	0,94	1,00

9.0.2 A.2. Canciones globales con distintos umbrales

Número de canciones presentes en el Top 200 de al menos m mercados y porcentaje medio de los streams de cada mercado que concentran.

[14]:
```
glob = pd.concat({
    m: compute_concentration_diagnostics(df_top200_annual, top_k=10,␣
 ↪min_markets=m)
        .set_index("year")[["global_hit_count", "global_hit_share"]]
    for m in (10, 20, 30)
}, axis=1)
print(glob.round(3))
```

```
---------------------------------------------------------------------------
KeyError                                  Traceback (most recent call last)
Cell In[14], line 1
----> 1 glob = pd.concat({
      2     m: compute_concentration_diagnostics(df_top200_annual, top_k=10,␣
 ↪min_markets=m)
      3         .set_index("year")[["global_hit_count", "global_hit_share"]]
      4     for m in (10, 20, 30)

File ~/proyectos/spotify-charts-convergencia/analisis/.venv/lib/python3.14/
 ↪site-packages/pandas/core/frame.py:4384, in DataFrame.__getitem__(self, key)
   4380                 indexer = [indexer]
   4381         else:
   4382             if is_iterator(key):
   4383                 key = list(key)
```

```
-> 4384             indexer = self.columns._get_indexer_strict(key, "columns")[ ]
   4385
   4386         # take() does not accept boolean indexers
   4387         if getattr(indexer, "dtype", None) == bool:

File ~/proyectos/spotify-charts-convergencia/analisis/.venv/lib/python3.14/
 ↪site-packages/pandas/core/indexes/base.py:6302, in Index.
 ↪_get_indexer_strict(self, key, axis_name)
   6299 else:
   6300     keyarr, indexer, new_indexer = self._reindex_non_unique(keyarr)
-> 6302 self._raise_if_missing(keyarr, indexer, axis_name)
   6304 keyarr = self.take(indexer)
   6305 if isinstance(key, Index):
   6306     # GH 42790 - Preserve name from an Index

File ~/proyectos/spotify-charts-convergencia/analisis/.venv/lib/python3.14/
 ↪site-packages/pandas/core/indexes/base.py:6352, in Index.
 ↪_raise_if_missing(self, key, indexer, axis_name)
   6350 if nmissing:
   6351     if nmissing == len(indexer):
-> 6352         raise KeyError(f"None of [{key}] are in the [{axis_name}]")
   6354     not_found = list(ensure_index(key)[missing_mask.nonzero()[0]].
 ↪unique())
   6355     raise KeyError(f"{not_found} not in index")

KeyError: "None of [Index(['global_hit_count', 'global_hit_share'],␣
 ↪dtype='str')] are in the [columns]"
```

Año	m = 10	m = 20	m = 30
2017	296 (78 %)	138 (56 %)	98 (48 %)
2018	307 (67 %)	108 (39 %)	63 (29 %)
2019	278 (57 %)	91 (31 %)	41 (20 %)
2020	263 (56 %)	85 (30 %)	38 (20 %)
2021	248 (53 %)	74 (28 %)	33 (18 %)

9.0.3 A.3. Concentración de las listas

Cuota media de streams que concentran las 5, 10 y 20 canciones principales de cada mercado.

[ ]:
```
conc_k = pd.DataFrame({
    f"top{k}": compute_concentration_diagnostics(df_top200_annual, top_k=k,␣
 ↪min_markets=20)
        .set_index("year")["top_k_share_mean"]
    for k in (5, 10, 20)
})
print((conc_k * 100).round(1))
```

```
      top5  top10  top20
year
2017   8.9   15.2   25.6
2018   7.6   13.7   23.8
2019   8.1   14.5   24.9
2020   8.0   14.1   24.1
2021   8.3   14.7   25.1
```

Año	Top 5	Top 10	Top 20
2017	8,9 %	15,2 %	25,6 %
2018	7,6 %	13,7 %	23,8 %
2019	8,1 %	14,5 %	24,9 %
2020	8,0 %	14,1 %	24,1 %
2021	8,3 %	14,7 %	25,1 %

La cuota se mantiene entre 13,7 % y 15,2 % para el top 10, sin aumento ni disminución sostenidos, por lo que la distancia no aumentó por un cambio en la concentración de las listas.